

تابع log-likelihood - صورت زیر است:  $\leftarrow$  تعداد داده ها

$$l(\pi, \mu, \sigma) = \ln P(X | \pi, \mu, \sigma) = \sum_{n=1}^N \ln P(x^n | \pi, \mu, \sigma)$$

$$= \sum_{n=1}^N \ln \sum_{z^n=1}^K \underbrace{P(x^n | z^n; \mu, \sigma) P(z^n | \pi)}_{\leftarrow \text{تعداد کلاس ها}}$$

$$\begin{aligned} P(x) &= \sum_z P(x|z)P(z) \text{ (مجموع)} \\ &= \sum_{n=1}^N \log \sum_{j=1}^K P(x^n, z^n=j | \theta) \end{aligned} \quad \theta = (\pi, \mu, \sigma)$$

عبارت داخل سیگما سمت راست را حد یک -  $q_j$  ضرب و تقسیم می کنیم:

$$l(x, \theta) = \sum_{n=1}^N \log \sum_{j=1}^K q_j \frac{P(x^n, z^n=j | \theta)}{q_j}$$

ناسا Jensen: اگر  $f$  تابع محدب باشد و  $P_1, P_2, \dots, P_n$  اعدادی 0 و 1 باشند که مجموع آن ها 1 است:

$$f\left(\sum_{i=1}^n P_i x_i\right) \geq \sum_{i=1}^n P_i f(x_i) = E[f(x)]$$

در نتیجه:

$$\sum_{n=1}^N \log \sum_{j=1}^K q_j \frac{P(x^n, z^n=j | \theta)}{q_j} \geq \sum_{n=1}^N \sum_{j=1}^K \overbrace{q_j \log \frac{P(x^n, z^n=j | \theta)}{q_j}}^Q$$

حال یک حدس خوب برای  $q_j$ ،  $P(z^n=j | x^n, \theta^{old})$  است ( $\theta^{old}$ : مقادیر قبلی پارامترها)

چرا؟ چون عبارت عددی و ساده می شود  $\frac{P(x^n, z^n | \theta)}{P(z^n=j | x^n, \theta^{old})}$  که همان  $P(x^n | z^n=j, \theta^{old})$  است.  
 در صورت ناسازی: ساده می تبدیل می شود.

در  $Q$  صورت زیر می شود:

$$Q(\theta) = \sum_{n=1}^N \sum_{j=1}^K P(z^n=j | x^n, \theta^{old}) \log(P(x^n, z^n=j | \theta))$$



$$Q(\theta) = E_{P(z^n | x^n, \theta^{old})} [\log P(x^n, z^n | \theta)]$$

مشتقی که  $\theta$  وابسته نبود حذف شده است

حالا یک متغیر  $z_k^n$  برای داده‌ی  $n$ ام و  $k$ ام تعریف می‌کنیم

$$\begin{aligned} \gamma_k^n &= P(z^n = k | x^n) \stackrel{\text{Bayes}}{=} \frac{P(x^n | z^n = k) P(z^n = k)}{P(x^n)} \\ &= \frac{\pi_k \mathcal{N}(x^n, \mu_k, \sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x^n, \mu_j, \sigma_j)} \end{aligned}$$

که  $\mathcal{N}$  همان pdf توزیع نرمال است.

حالا  $z_k^n$  را در فرمول تابع  $Q$  جایگذاری می‌کنیم:

$$\begin{aligned} E_{P(z^n | x^n)} \left[ \sum_{n=1}^N \log(P(x^n, z^n | \theta)) \right] \\ = \sum_{n=1}^N \sum_{k=1}^K \gamma_k^n \left( \underbrace{\log(\pi_k)}_{\pi_k} + \log \left( \underbrace{P(x^n | z^n = k, \theta)}_{\mathcal{N}(x^n, \mu_k, \sigma_k)} \right) \right) \\ = \sum_{n=1}^N \sum_{k=1}^K \gamma_k^n \log(\pi_k) + \sum_{k=1}^K \sum_{n=1}^N \gamma_k^n \log(\mathcal{N}(x^n, \mu_k, \sigma_k)) \end{aligned}$$

حالا این تابع را در که optimize می‌کنیم (یعنی  $\pi_k$  و  $\mu_k$  و  $\sigma_k$ )، اصولی انتخاب می‌کنیم که آن optimize کنه.



سوال (1)  
نمت (2) اثبات غير ترولى بدون Q

مى دانيم در مصلدى  $M$ ، پارامترها با فرض اول زیر آيديت مى شوند:

$$\mu_k^* = \frac{1}{N_k} \sum_{n=1}^N \gamma_k^n x^n$$

$$\sigma_k^* = \frac{1}{N_k} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k^*)^2$$

$$\pi_k^* = \frac{N_k}{N}$$

به صورتى:  $N_k = \sum_{n=1}^N \gamma_k^n$  تعريف شده است.

اثبات مى كنيم كه مقادير نمت راست، همان مقادير اكستريم مطلق تابع  $Q$  بر حسب  $\mu, \sigma, \pi$  هستند. در انصورت چون طبق تعريف اكستريم،  
 $Q(\pi', \mu', \sigma') \leq Q(\pi^*, \mu^*, \sigma^*)$   
 $\forall \pi', \mu', \sigma'$  مصلدى مبدى  $Q$

در انصورت  $Q$  مصلدى مبدى ممتا از  $Q$  مصلدى متبلى ميشود خواهد بود.

$$Q(\theta | \theta^{old}) = \sum_{k=1}^K \sum_{n=1}^N \gamma_k^n \log \pi_k + \sum_{k=1}^K \sum_{n=1}^N \gamma_k^n \left[ \frac{1}{\sqrt{2\pi} \sigma_k} e^{-\frac{1}{2} \left( \frac{x^n - \mu_k}{\sigma_k} \right)^2} \right]$$

$$\mathcal{L}(Q(\pi)) = \sum_{k=1}^K \sum_{n=1}^N \gamma_k^n \log \pi_k - \lambda \left( \sum_{k=1}^K \pi_k - 1 \right) \quad \sum_{k=1}^K \pi_k = 1$$

ضريب لاگرانژ

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \left( \sum_{n=1}^N \gamma_k^n \right) \times \frac{1}{\pi_k} - \lambda \times 1 = 0 \rightarrow \pi_k = \frac{1}{\lambda} \times \sum_{n=1}^N \gamma_k^n$$

جايگذاشتن در Constraint:  $\sum_{k=1}^K \pi_k = 1 \rightarrow \sum_{k=1}^K \left( \frac{1}{\lambda} \sum_{n=1}^N \gamma_k^n \right) = 1 \rightarrow \lambda = \sum_{k=1}^K \sum_{n=1}^N \gamma_k^n$

$\pi_k = \frac{\sum_{n=1}^N \gamma_k^n}{\sum_{k=1}^K \sum_{n=1}^N \gamma_k^n}$ 
 $= \sum_{n=1}^N \left( \frac{\sum_{k=1}^K \gamma_k^n}{\sum_{k=1}^K \sum_{n=1}^N \gamma_k^n} \right) = \sum_{n=1}^N \left( \frac{\sum_{k=1}^K \gamma_k^n}{N} \right) = N$



برای اینکه بدانیم مقدار بهینه‌ی بدست آمده برای  $\arg\max_k \pi_k$  مطلق  $Q$  بر حسب  $\pi_k$  است و نه  $\arg\max$  نسبی، مشتق دوم  $Q$  بر حسب  $\pi_k$  را می‌گیریم

$$\frac{\partial^2 Q}{(\partial \pi_k)^2} = \left( \sum_{n=1}^N \gamma_k^n \right) x - \frac{1}{\pi_k^2} \leq 0$$

هر  $\gamma_k^n$  مثبت است  
پس این مقدار مثبت است

پس چون تقعر تابع  $Q$  بر حسب  $\pi_k$  همواره منفی است، مقدار بدست آمده برای  $\pi_k$  در حقیقت مطلق، ماکزیمم مطلق است.

$$\frac{\partial Q}{\partial \mu_k} = \sum_{n=1}^N \gamma_k^n \times \left( +\frac{1}{2} \right) \times \left( +\frac{1}{\sigma_k} \right) \times 2 \times \left( \frac{x^n - \mu_k}{\sigma_k} \right)$$

$$= \frac{1}{\sigma_k^2} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k)$$

$$\frac{\partial Q}{\partial \mu_k} = 0 \rightarrow \frac{1}{\sigma_k^2} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k) = 0$$

$$\rightarrow \sum_{n=1}^N \gamma_k^n \times x^n - \sum_{n=1}^N \gamma_k^n \times \underbrace{\mu_k}_{\text{مستقل از } n} = 0$$

$$\rightarrow \mu_k^+ = \frac{\sum_{n=1}^N \gamma_k^n x^n}{\sum_{n=1}^N \gamma_k^n}$$

حالا اگر مشتق دوم  $Q$  نسبت به  $\mu_k$  را بگیریم:

$$\frac{\partial^2 Q}{(\partial \mu_k)^2} = \frac{1}{\sigma_k^2} \times \sum_{n=1}^N \gamma_k^n (-1) = - \frac{\sum_{n=1}^N \gamma_k^n}{\sigma_k^2} \leq 0$$

پس  $Q$  بر حسب  $\mu_k$  هم محدب است، پس نقطه‌ی بهینه‌ی بدست آمده برای  $\mu_k$ ،  $\arg\max$  مطلق  $Q$  است.



ادله‌ی سؤال (1) نسبت (2) اثبات غیر تریک بدون Q

$$\frac{\partial Q}{\partial \sigma_k} = \frac{1}{\sqrt{2\pi}} \times \left( \frac{-1}{\sigma_k^2} \right) \times \sqrt{2\pi} \sigma_k \times \sum_{n=1}^N \gamma_k^n$$

$$+ \sum_{n=1}^N \gamma_k^n \times \left( -\frac{1}{2} \right) \times (x^n - \mu_k) \times \frac{1}{\sigma_k^2} \times 2 \left( \frac{x^n - \mu_k}{\sigma_k} \right)$$

$$\frac{\partial Q}{\partial \sigma_k} = - \frac{\sum_{n=1}^N \gamma_k^n}{\sigma_k} + \frac{1}{\sigma_k^3} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k)^2 = 0$$

از آنجایی که  $\sigma_k = 0$  خوددلفنی تابع نیست،

$$\rightarrow - \sum_{n=1}^N \gamma_k^n + \frac{1}{\sigma_k^2} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k)^2 = 0$$

$$\rightarrow \sigma_k^2 = \frac{\sum_{n=1}^N \gamma_k^n (x^n - \mu_k)^2}{\sum_{n=1}^N \gamma_k^n}$$

حالا اگر مشتق دوم بگیریم با در حالت قبل که فرق دارد:

$$\frac{\partial^2 Q}{(\partial \sigma_k)^2} = \frac{-3}{\sigma_k^4} \sum_{n=1}^N \gamma_k^n (x^n - \mu_k)^2 + \frac{\sum_{n=1}^N \gamma_k^n}{\sigma_k^2} = 0$$

$$\frac{-3}{\sigma_k^2} \times \sum_{n=1}^N \gamma_k^n (x^n - \mu_k)^2 + \sum_{n=1}^N \gamma_k^n = 0$$


در این مشتق دوم یک <sup>نسبت</sup>  $\frac{1}{\sigma_k}$  دارد. پس با مشتق دوم نمی توان اثبات کرد که نقطه‌ی بهینه‌ی آمده، بهینه‌ی مطلق است و نه نسبی. اما با رسم شکل تابع مشتق می توان این کار را کرد. وقت می کشیم که  $\frac{\partial Q}{\partial \sigma_k}$  م فرم  $\frac{1}{\sigma_k} \left( -A + \frac{B}{\sigma_k^2} \right)$  است. و برای اخراج عبارات فقط کماهای بزرگتر از صفر را قابل قبول می دانیم (صحت در حالت ماکزیمم همیشه است)




ادامه سوال (1) قسمت (2) اثبات غیر نزولی بودن Q

$$\sigma_k > 0$$

$$f(\sigma_k) = \frac{1}{\sigma_k^2}$$




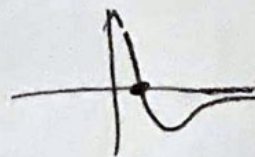
$$f(\sigma_k) = \frac{B}{\sigma_k^2}$$



$$\frac{\partial Q}{\partial \sigma_k} = \frac{1}{\sigma_k} \left( -A + \frac{B}{\sigma_k^2} \right)$$

که  $0 \leq B, A$



حالا اگر  $\frac{1}{\sigma_k}$  را در تابع فوق ضرب کنیم، با توجه به اینکه  $\sigma_k$  همواره نزدیکتر از 0 است، درست است که شکل تابع تغییری کند (در واقع به صورت  در می آید) اما ریشه‌ی جدیدی تولید نمی‌شود. پس ریشه‌ی مثبت، اکثر هم مطلق است و چون مشتق قبل از آن مثبت و بعد از آن منفی است، پس مقدار Q در  $\sigma_k$  به دست آمده تاکنون مطلق است نه منفی.

پس چون مقدارهای  $\sigma$  در  $\pi$  در M-step  $\arg \max$  مطلق Q است، پس Q مرحله‌ی جدید نمی‌تواند از Q مرحله‌ی قبل کمتر باشد.